Khung Kiến Trúc Nén Token Video Dài 2 Giai Đoạn

Giai Đoạn 1: Tiền Huấn Luyện Không Gian Tiềm Ẩn V-JEPA 2.1 (Vật Lý Thô) → Giai Đoạn 2: Tinh Chỉnh Phân Nhánh: 2A (Query-Agnostic Captioning) & 2B (Query-Aware VQA)

GIAI ĐOẠN 1: PHYSICAL FOUNDATION

V-JEPA 2.1 Latent Loss

Học không giám sát: Tái tạo động lực học thế giới vật lý

HƯỚNG 2A: QUERY-AGNOSTIC

Captioning Alignment

Triệt tiêu xung đột gradient, bảo toàn bối cảnh vĩ mô

HƯỚNG 2B: QUERY-AWARE

Targeted VQA Tuning

Cross-Attention truy vấn, truy tìm bằng chứng chuyên sâu

HIỆU QUẢ SUY LUẬN (INFERENCE)

One-Pass Feature

Dùng trực tiếp VLM Encoder, DSTA Policy dưới 8ms

1. Triết Lý Thiết Kế 2 Giai Đoạn: Từ Nền Tảng Vật Lý Khách Quan Đến Ngữ Nghĩa Ứng Dụng

Giai Đoạn 1: Physical Foundation Pre-training (Thô)

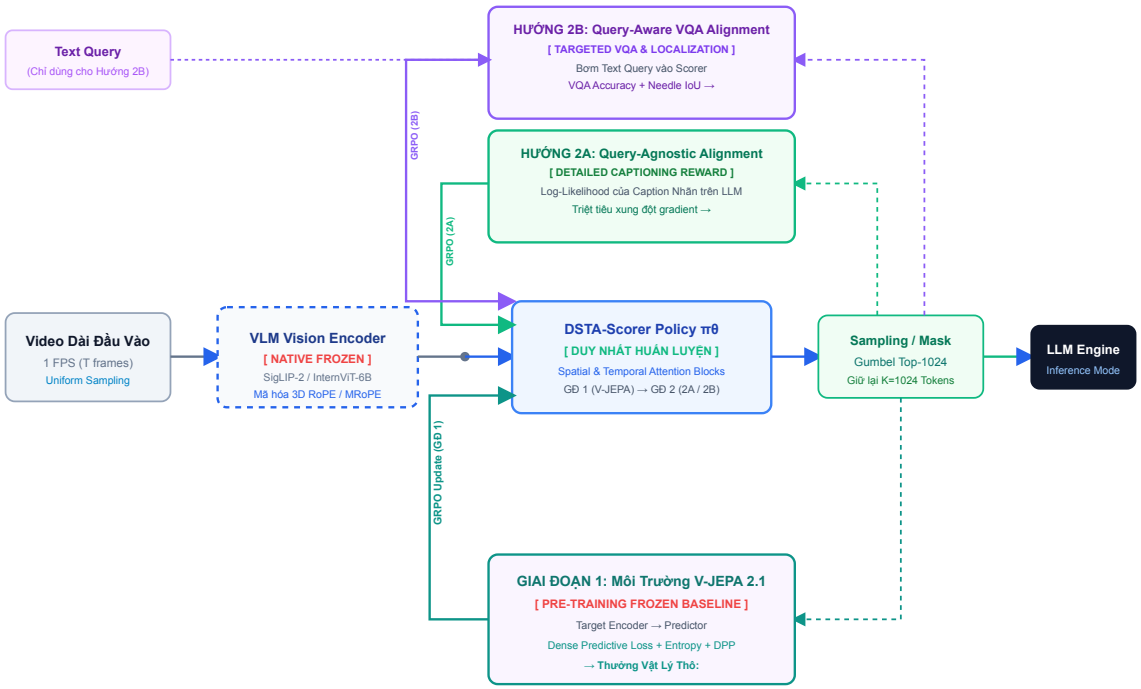
UNSUPERVISED WORLD MODEL

- **Bản chất:** Đóng vai trò là bộ lọc vật lý độc lập truy vấn (Query-Agnostic Foundation).
- **Cơ chế học:** Huấn luyện mạng **DSTA-Scorer** bằng RL (GRPO) trên không gian tiềm ẩn của **V-JEPA 2.1** (đóng băng).
- **Mục tiêu:** Nhận diện các vùng không gian - thời gian chứa đựng sự thay đổi trạng thái, tương tác và tính liên tục nhân quả của video.
- **Ưu điểm:** Không bị phụ thuộc vào câu hỏi, tránh ảo giác từ khóa và ngăn chặn hiện tượng mất bối cảnh vĩ mô.

Giai Đoạn 2: Downstream Task Alignment (Tinh) SUPERVISED FINE-TUNING

- **Bản chất:** Kế thừa trọng số Giai đoạn 1 làm điểm khởi động lạnh (Cold-start) vững chắc, tinh chỉnh chuyên sâu theo mục tiêu triển khai.
- **Cơ sở phân nhánh:** Tùy thuộc vào yêu cầu của hệ thống suy luận thực tế:
  - **Hướng 2A (Query-Agnostic):** Không đưa text vào bộ nén, sử dụng dữ liệu Detailed Captioning để tối ưu hóa biểu diễn tổng quát dùng chung cho mọi câu hỏi.
  - **Hướng 2B (Query-Aware):** Đưa text câu hỏi vào bộ nén, sử dụng dữ liệu VQA để truy tìm bằng chứng sắc nhọn cho câu hỏi chuyên sâu.

2. Sơ Đồ Hệ Thống Huấn Luyện 2 Giai Đoạn & Hai Nhánh Tinh Chỉnh Hạ Nguồn



3. Giai Đoạn 1: Tiền Huấn Luyện Không Gian Tiềm Ẩn V-JEPA 2.1 (Baseline Foundation)

3.1. Nhiệm Vụ Cốt Lõi Của Giai Đoạn 1: Thiết Lập Thước Đo Vật Lý Thô

Tại Giai đoạn 1, DSTA-Scorer được huấn luyện hoàn toàn theo cơ chế **Query-Agnostic** trên kho dữ liệu video không nhãn. Nhiệm vụ của mạng là tìm kiếm tập hợp $K = 1024$ tokens sao cho khi che khuất (masking) các tokens còn lại, bộ Predictor của V-JEPA 2.1 có thể nội suy chính xác nhất các biểu diễn tiềm ẩn bị mất.

$$R_{\text{Stage1}}(\mathbf{m}) = \underbrace{-\log\left(\mathcal{L}_{\text{predict}}^{\text{V-JEPA}}(\mathbf{m}) + \epsilon\right)}_{\text{Physical Dynamics}} + \underbrace{\lambda_{\text{ent}}\mathcal{H}(P)}_{\text{Temporal Coverage}} + \underbrace{\lambda_{\text{dpp}}\mathcal{R}_{\text{DPP}}(}_{\text{Spatial Divers}}$$

Chi tiết Entropy $\mathcal{H}(P)$ (Temporal Coverage):

Tính trên phân phối thời gian cận biên: $P_T(t) = \sum_{i=1}^{N} P_{t,i}$.

$$\mathcal{H}(P) = -\sum_{t=1}^{T} P_T(t) \log\left(P_T(t) + \epsilon\right)$$

Ngăn chặn tác tử dồn toàn bộ xác suất vào frame đầu/cuối, ép mạng phải phân bổ xác suất tìm kiếm dọc theo trục thời gian video.

Chi tiết Đa dạng DPP $\mathcal{R}_{\text{DPP}}(S)$ (Spatial Diversity):

Xây dựng ma trận Gram $\mathbf{K}_S[a, b] = \mathbf{z}_a^\top \mathbf{z}_b$ từ các tokens chuẩn hóa.

$$\mathcal{R}_{\text{DPP}}(S) = \frac{1}{K} \log\det\left(\mathbf{K}_S + \delta \mathbf{I}\right)$$

Định thức đo bình phương thể tích hình hộp vector. Nếu các token bị trùng lặp, $\det \to 0$ dẫn đến hình phạt cực lớn, ép mạng chọn các chi tiết trực giao bổ sung cho nhau.

4. Giai Đoạn 2: Hai Hướng Tinh Chỉnh Chuyên Sâu Tác Vụ Hạ Nguồn

Hướng 2A: Query-Agnostic Downstream Alignment (Ưu Tiên Video Captioning)

CONFLICT-FREE
GENERAL CONTEXT

A. Cơ Sở Lý Thuyết: Khử Xung Đột Gradient Của Dữ Liệu VQA

Nếu ta tiếp tục duy trì kiến trúc **Query-Agnostic** (không đưa câu hỏi vào bộ nén) nhưng lại huấn luyện trên tập dữ liệu Question Answering, mạng Policy sẽ đối mặt với thảm họa xung

đột gradient:

> **Nghịch lý 1 Video - Đa Câu Hỏi (Multi-Question Gradient Conflict):** Với cùng một video, câu hỏi Q_1 hỏi về người đi bộ ở góc trái frame 10; câu hỏi Q_2 hỏi về biển số xe ở góc phải frame 80. Khi không có thông tin truy vấn, mạng Policy buộc phải đưa ra **cùng một tập 1024 tokens duy nhất** cho cả 2 câu hỏi. Gradient cập nhật từ Q_1 và Q_2 sẽ kéo các trọng số theo các hướng vuông góc hoặc đối nghịch nhau, triệt tiêu tín hiệu học và khiến mạng suy biến thành một bộ lọc trung bình vô nghĩa.

B. Giải Pháp: Huấn Luyện Bằng Detailed / Dense Video Captioning

- **Mô tả toàn cảnh:** Sử dụng các tập dữ liệu mô tả phân cấp chi tiết. Captioning yêu cầu thuật lại toàn bộ dòng chảy diễn biến sự kiện, hành động và thực thể từ đầu đến cuối video.
- **Tập trung không mâu thuẫn:** Mọi token mô tả hành động cốt lõi đều đóng góp đồng thuận vào việc tái tạo văn bản, tạo ra vector gradient nhất quán hướng về các sự kiện chính.

C. Thiết Kế Hàm Phần Thưởng Cho Hướng 2A (R_{Stage2A})

Đưa $K = 1024$ tokens được chọn S qua Projector và LLM đóng băng để tính xác suất giải mã chuỗi Caption nhãn $y^* = (y_1^*, y_2^*, \dots, y_L^*)$ có độ dài L:

$$R_{\text{Stage2A}}(S) = \frac{1}{|y^*|} \sum_{t=1}^{|y^*|} \log P_{\text{LLM}}\left(y_t^* \mid y_{1:t-1}^*, \{z_k\}_{k \in S}\right) - \beta_{\text{KL}} D_{\text{KL}}\left(\pi_\phi\right.$$

- $\log P_{\text{LLM}}\left(y_t^* \mid y_{1:t-1}^*, \{z_k\}_{k \in S}\right)$**:** Log-likelihood tự hồi quy của từng token từ ngữ trong caption chuẩn, có điều kiện trên các visual tokens được giữ lại. Thưởng tối đa khi LLM chỉ nhìn 1024 tokens được chọn mà vẫn giải mã văn bản mô tả với độ tự tin cao nhất.
- **Anchor KL Regularization:** Giữ chính sách không đi quá xa so với Giai đoạn 1, đảm bảo tính toàn vẹn động lực học vật lý đã học từ V-JEPA 2.1.

Hướng 2B: Query-Aware Task-Specific Alignment (Chuyên Sâu Cho VQA & Needle Retrieval)

TARGETED EVIDENCE SEEKING

A. Kiến Trúc Mạng Policy: Query-Modulated DSTA

Trong kịch bản hệ thống cho phép nhận câu hỏi Q ngay từ khâu lọc token, ta mở rộng mạng DSTA-Scorer bằng cách bổ sung một khối **Cross-Attention nhẹ** (hoặc FiLM conditioning). Vector nhúng câu hỏi $\mathbf{e}_Q$ sẽ điều hướng dòng chú ý của bộ chọn:

$$s_{t,i}^{(Q)} = \text{DSTA-Scorer}\left(z_{t,i}, \Delta z_{t,i} \;\middle|\; \mathbf{e}_Q\right)$$

B. Cơ Chế Thưởng Lấy Cảm Hứng Từ Các Nghiên Cứu Tiên Phong

Lấy cảm hứng từ cơ chế học tăng cường tối ưu hóa chính sách lấy mẫu thời gian (như phương pháp TSPO) và tối ưu hóa nén token động dựa trên lợi thế phân tách (như phương pháp SCORE), hàm phần thưởng được cấu thành bởi các mục tiêu giám sát chuyên biệt:

$$R_{\text{Stage2B}}(S) = w_{\text{acc}} R_{\text{acc}} + w_{\text{loc}} R_{\text{loc}} + w_{\text{perf}} R_{\text{perf}} - \beta_{\text{KL}} D_{\text{KL}}\left(\pi_\phi(S|Q) \right.$$

THÀNH PHẦN THƯỞNG	CÔNG THỨC TOÁN HỌC	Ý NGHĨA KỸ THUẬT
1. Task Accuracy (R_{acc})	$R_{\text{acc}} = \begin{cases} 1.0 & \text{nếu } \hat{y}(S,Q) = y^* \\ \text{Soft-Score}(y^*, \hat{y}) & \text{khác} \end{cases}$	Đo lường độ chính xác câu trả lời sinh ra bởi

THÀNH PHẦN THƯỞNG	CÔNG THỨC TOÁN HỌC	Ý NGHĨA KỸ THUẬT
		LLM đối với các câu hỏi trắc nghiệm hoặc sinh tự do (Open-ended QA).
2. Temporal Localization (R_{loc})	$$R_{\text{loc}} = \frac{\lvert S \cap \text{Temporal-GroundTruth} \rvert}{\lvert S \rvert}$$	Lấy cảm hứng từ các nghiên cứu định vị thời gian: Thưởng lớn nếu các token được chọn rơi trúng khoảng thời gian chứa biến cố sự kiện cần trả lời (Needle-in-a-Haystack).
3. Performance Gain (R_{perf})	$$R_{\text{perf}} = \text{CE}_{\text{FullTokens}}(y^*) - \text{CE}_{\text{Subset-}S}(y^*)$$	Lấy cảm hứng từ các phương pháp tối ưu hóa ngân sách token động: Thưởng dương khi tập nén 1024 tokens loại

THÀNH PHẦN THƯỞNG	CÔNG THỨC TOÁN HỌC	Ý NGHĨA KỸ THUẬT
		bỏ được nhiễu, cho loss dự đoán tốt hơn hoặc bằng tập full tokens.

5. Ma Trận Đánh Giá So Sánh Giữa Các Hướng Triển Khai

TIÊU CHÍ KỸ THUẬT	GIAI ĐOẠN 1 (V-JEPA BASELINE)	HƯỚNG 2A (QUERY-AGNOSTIC CAPTIONING)	HƯỚNG 2B (QUERY-AWARE VQA)
Đầu vào mạng Policy	Chỉ Visual Tokens ($T \times N$)	Chỉ Visual Tokens ($T \times N$)	Visual Tokens + Text Query (Q)
Dữ liệu huấn luyện	Video không nhãn (Kinetics/CC3M)	Detailed / Dense Video Captions	Video QA / Needle Datasets
Hiện tượng Gradient Conflict	Không có (Unsupervised)	**Triệt tiêu hoàn toàn (Nhờ Captioning)**	Được giải quyết nhờ điều kiện hóa theo Query
Đặc tính tập token đầu ra	Bảo toàn động lực học vật lý thô	Bảo toàn bối cảnh vĩ mô toàn diện	Tập trung sắc nhọn vào bằng chứng câu hỏi

TIÊU CHÍ KỸ THUẬT	GIAI ĐOẠN 1 (V-JEPA BASELINE)	HƯỚNG 2A (QUERY-AGNOSTIC CAPTIONING)	HƯỚNG 2B (QUERY-AWARE VQA)
Khả năng tái sử dụng (Reusability)	Dùng chung cho mọi tác vụ downstream	**1 lần nén → Trả lời mọi câu hỏi sau đó**	Mỗi câu hỏi mới phải chạy lại mạng Scorer
Nền tảng tham khảo	V-JEPA 2.1 Latent World Architecture	Caption Alignment & Language Modeling	Temporal Sampling Policy & Dynamic Token Gating

6. Lộ Trình Triển Khai Thực Nghiệm Đề Xuất

1. **Giai đoạn 1: Tiền huấn luyện nền tảng vật lý thô (Pre-training Baseline)**
   - Dữ liệu: Video-CC3M / Kinetics-700 (không cần nhãn).
   - Đóng băng Vision Encoder và V-JEPA 2.1. Huấn luyện DSTA-Scorer đạt trạng thái hội tụ về sai số nội suy tiềm ẩn để thu được checkpoint θ^*_{Stage1}.
2. **Lựa chọn hướng triển khai Giai đoạn 2:**
   - **Triển khai Hướng 2A (Khuyến nghị cho Hệ Thống Tự Động):** Nạp checkpoint θ^*_{Stage1}, tinh chỉnh với dữ liệu Video Captioning chất lượng cao. Thu được bộ nén Query-Agnostic hoàn hảo, nén 1 lần duy nhất cho toàn bộ video, sau đó LLM có thể trả lời hàng chục câu hỏi liên tiếp mà không cần chạy lại bộ nén.
   - **Triển khai Hướng 2B (Dành cho Tác Vụ Cần Độ Chính Xác Cực Hạn):** Nạp checkpoint θ^*_{Stage1}, bổ sung Cross-Attention cho câu hỏi và tinh chỉnh với Video-QA. Bộ nén sẽ lọc trúng tuyệt đối các phân đoạn chứa câu trả lời cho các câu hỏi needle-in-a-haystack phức tạp.
3. **Đánh giá Benchmark chuẩn quốc tế**
   - Đánh giá chéo cả 2 hướng trên **Video-MME**, **MLVU**, và **LongVideoBench**.
   - So sánh định lượng: Accuracy, Time-to-First-Token (TTFT), và tỷ lệ cắt giảm KV-Cache của LLM so với baseline Uniform Sampling và các phương pháp truyền thống khác.

> **Thông điệp chốt:** *"Giai đoạn 1 trang bị cho bộ nén đôi mắt vật lý khách quan để hiểu bản chất chuyển động thế giới. Ở Giai đoạn 2, việc phân tách thành Hướng 2A (Captioning) giúp tạo ra một bộ nén độc lập truy vấn không bao giờ bị mâu thuẫn dữ liệu, trong khi Hướng 2B (VQA) mang lại khả năng truy vấn bằng chứng mục tiêu sắc bén nhất. Đây là giải pháp hoàn chỉnh, mạch lạc và tối ưu tài nguyên tuyệt đối cho bài toán video dài."*

Tài Liệu Kỹ Thuật Chuyên Sâu — Hệ Thống Cắt Tỉa Token Video Dài Cho Multimodal LLMs