Hệ Thống Cắt Tỉa Token Video Dài Không Phụ Thuộc Truy Vấn

Tận Dụng Native Vision Encoder Của VLM, Tối Ưu Hóa Mạng Policy Spatio-Temporal Attention Qua Phần Thưởng Tiềm Ẩn V-JEPA 2.1

VISION BACKBONE SỬ DỤNG

VLM-Native Encoder

SigLIP-2 / InternViT (Đã căn chỉnh video đa phương thức)

KIẾN TRÚC MẠNG POLICY

DSTA-Scorer

Decoupled Spatial & Temporal Attention (Tuyến tính phân rã)

TÍN HIỆU PHẦN THƯỞNG (RL)

V-JEPA 2.1 Latent Loss

Dự đoán thế giới tiềm ẩn, không giải mã pixel

CHI PHÍ TÍNH TOÁN SUY LUẬN

Zero Extra Feature Pass

Encode 1 lần duy nhất, DSTA Policy overhead < 8ms

1. Phân Tích Chiến Lược: Tại Sao Phải Dùng Native Vision Encoder Của VLM?

A. Điểm Yếu Của Vision Encoder Độc Lập Bên Ngoài

HIGH REDUNDANCY & GAP

- **Gánh nặng tính toán kép (Dual-Inference Overhead):** Nếu dùng CLIP hoặc DINOv2 ngoài làm bộ chọn, khi inference hệ thống phải:
  1. Chạy encoder ngoài để trích xuất đặc trưng cho toàn bộ video dài.
  2. Chạy bộ chọn để lấy Top-K tokens/frames.
  3. Đưa các frames đó qua Vision Encoder của VLM một lần nữa để lấy đặc trưng đưa vào LLM.

  Điều này làm tăng gấp đôi bộ nhớ VRAM và thời gian trích xuất đặc trưng (TTFT) ở khâu tiền xử lý.
- **Lệch pha không gian biểu diễn (Feature Misalignment):** DINOv2 học self-supervised trên cấu trúc hình học cục bộ; CLIP học contrastive tĩnh trên ảnh. Cả hai không có tri thức về cách LLM hiểu bối cảnh video. Token được DINOv2 coi là "quan trọng" (nhiều texture) có thể là nhiễu đối với LLM.

B. Lợi Thế Vượt Trội Của VLM-Native Vision Encoder OPTIMAL ALIGNMENT

- **Kế thừa tri thức video sẵn có:** Các Vision Encoder của VLM hiện đại (như SigLIP-2 của Qwen3-VL hay InternViT của InternVL3.5) đã trải qua hàng nghìn tỷ tokens huấn luyện đa phương thức (Omni-modal / Interleaved video-text data). Chúng được tích hợp sẵn **3D RoPE** hoặc **Interleaved MRoPE**, tự động hiểu được mối tương quan không gian - thời gian vượt trội hơn hẳn các mô hình ảnh tĩnh.
- **Căn chỉnh tự nhiên với LLM:** Dù LLM được đóng băng và không tham gia vòng lặp RL, đặc trưng từ chính encoder của VLM sẽ tương thích hoàn hảo với Projector/Aligner phía sau, không gây méo mó biểu diễn.
- **Hiệu quả thực tế (One-Pass Inference):** Toàn bộ video chỉ đi qua Vision Encoder **đúng 1 lần**. Policy chọn xong là token được chuyển thẳng tới LLM.

2. Thiết Kế Mạng Policy: Spatio-Temporal Attention Scorer (DSTA)

2.1. Phân Tích Vì Sao Mạng MLP Độc Lập Chắc Chắn Thất Bại

Giả sử video đầu vào gồm T khung hình, mỗi khung hình sinh ra N visual tokens ($N = H \times W$). Tổng số tokens là $M = T \times N$. Nếu ta sử dụng một mạng MLP độc lập $f_\theta : \mathbb{R}^D \to \mathbb{R}$ để tính điểm cho từng token riêng lẻ $s_{t,i} = f_\theta(z_{t,i})$:

> **1. Lỗi "Mù Thời Gian" (Temporal Blindness):**
> MLP chỉ nhìn vào đúng vector $z_{t,i}$ tại patch (t, i). Nó không hề biết liệu patch này đang đứng yên hay đang chuyển động nhanh, vì nó không thể so sánh với $z_{t-1,i}$ hay $z_{t+1,i}$. Một bức tường có hoa văn phức tạp sẽ cho ra score cực cao ở **mọi khung hình**.

> **2. Sụp Đổ Do Trùng Lặp (Redundancy Collapse):**
> Do Softmax toàn cục chỉ thực hiện trên mảng 1D các điểm số độc lập, thuật toán Top-K sẽ gom toàn bộ các token có score cao nhất. Nếu một vùng nền chiếm ưu thế, Top-1024 tokens sẽ bị chiếm trọn bởi nền tĩnh của nhiều frame liên tiếp, bỏ sót hoàn toàn các chuyển động vi mô chớp nhoáng của chủ thể.

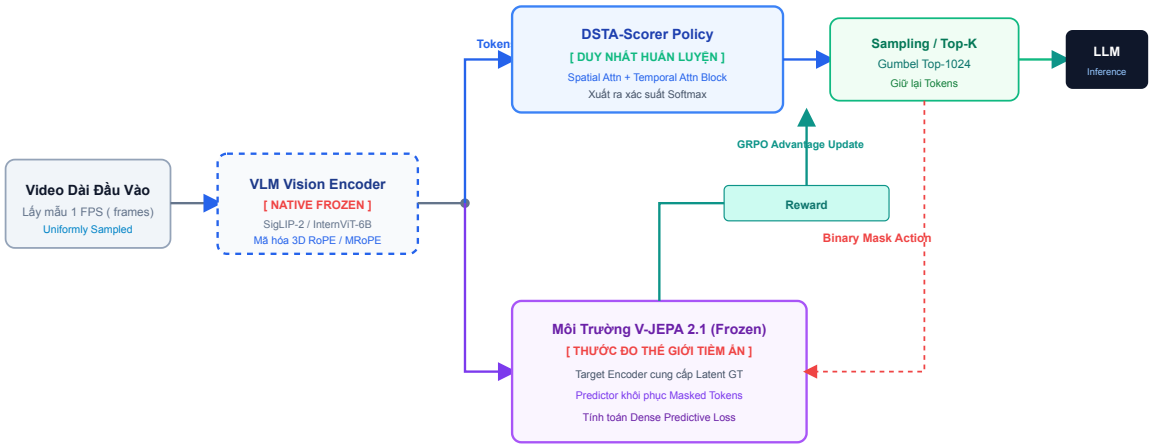
2.2. Giải Pháp: Decoupled Spatio-Temporal Attention Scorer (DSTA-Scorer)

Để token có thể "giao tiếp" với toàn bộ video mà không làm bùng nổ chi phí tính toán $\mathcal{O}((TN)^2)$, ta thiết kế mạng Policy theo kiến trúc **Chú ý phân tách không gian - thời gian (Factorized Spatio-Temporal Attention)** với tham số cực nhẹ ($\sim 2.5\text{M}$ parameters):

KHỐI CHỨC NĂNG	CƠ CHẾ TÍNH TOÁN (MATHEMATICAL FORMULATION)	Ý NGHĨA KỸ THUẬT
1. Temporal Difference Injection	$\tilde{z}_{t,i} = \text{LayerNorm}\left(z_{t,i} \,\|\, (z_{t,i} - z_{t-1,i})\right)\mathbf{W}_{\text{in}}$	Bơm trực tiếp vi sai chuyển động vào đặc trưng token, giúp mạng cảm nhận ngay vận tốc thay đổi cục bộ.
2. Spatial Attention Block *(Intra-frame Saliency)*	Tại mỗi frame t, tính Self-Attention giữa N tokens nội khung: $$\mathbf{Z}_t^{\text{spa}} = \mathbf{Z}_t + \text{Softmax}\left(\frac{\mathbf{Q}_{\text{spa}}\mathbf{K}_{\text{spa}}^\top}{\sqrt{d}}\right)\mathbf{V}_{\text{spa}}$$	Đo lường độ nổi bật của token so với toàn bộ bối cảnh của chính khung hình đó (phân biệt chủ thể vs. nền). Chi phí: $\mathcal{O}(T \cdot N^2)$.
3. Temporal Attention Block *(Inter-frame Novelty)*	Giữ nguyên tọa độ không gian i, tính Attention qua T khung hình: $$\mathbf{Z}_i^{\text{tem}} = \mathbf{Z}_i^{\text{spa}} + \text{Softmax}\left(\frac{\mathbf{Q}_{\text{tem}}\mathbf{K}_{\text{tem}}^\top}{\sqrt{d}}\right)\mathbf{V}_{\text{tem}}$$	So sánh token với chính nó qua dòng thời gian. Nếu token không thay đổi theo thời gian, attention score sẽ tự động triệt tiêu (chống redundancy). Chi phí: $\mathcal{O}(N \cdot T^2)$.
4. Scoring Head & Global Selection	$$s_{t,i} = \mathbf{w}^\top \text{GELU}(\mathbf{W}_2 \mathbf{Z}_{t,i}^{\text{tem}} + \mathbf{b}_2)$$ $$P(t,i) = \frac{\exp(s_{t,i}/\tau)}{\sum_{t'=1}^{T}\sum_{j=1}^{N}\exp(s_{t',j}/\tau)}$$	Xuất ra điểm số scalar phân phối trên toàn bộ video. Token nào có cả độ nổi bật không gian cao

KHỐI CHỨC NĂNG	CƠ CHẾ TÍNH TOÁN (MATHEMATICAL FORMULATION)	Ý NGHĨA KỸ THUẬT
		và độ mới theo thời gian sẽ nhận xác suất giữ lại lớn nhất.

3. Toàn Cảnh Quy Trình Huấn Luyện RL & Môi Trường Phản Hồi V-JEPA 2.1



4. Công Thức Toán Học & Thuật Toán Học Tăng Cường GRPO

A. Hàm Phần Thưởng Thế Giới Tiềm Ẩn (V-JEPA Reward)

LATENT REWARD

Hành động của mạng DSTA-Scorer là tạo ra một mask nhị phân $\mathbf{m} \in \{0,1\}^M$, trong đó đúng $K = 1024$ tokens có giá trị 1 (được giữ lại), còn lại các tokens có giá trị 0 (bị loại bỏ, ký hiệu tập M_{mask}). Ta thay thế các token bị loại bỏ bằng learnable mask tokens và nạp vào Predictor của V-JEPA 2.1:

$$\mathcal{L}_{\text{predict}}(\mathbf{m}) = \frac{1}{|M_{\text{mask}}|} \sum_{j \in M_{\text{mask}}} \left\| P_\phi(\{z_k\}_{k \in S}, \mathbf{e}_{\text{mask}})_j - \text{sg}\left(E_{\bar{\theta}}(V)_j\right) \right\|_1$$

- **Loss càng nhỏ:** Chứng tỏ các tokens được giữ lại đã chứa đủ bằng chứng vật lý cốt lõi để mô hình thế giới nội suy ra toàn bộ diễn biến video.
- **Công thức Reward:**

  $$R(\mathbf{m}) = -\log\left(\mathcal{L}_{\text{predict}}(\mathbf{m}) + \epsilon\right) + \lambda_{\text{div}} \mathcal{H}(P)$$

  Trong đó $\mathcal{H}(P)$ là Entropy để tránh hiện tượng mạng policy hội tụ sớm về một vài khung hình cố định.

  > **Chi tiết tính toán Entropy $\mathcal{H}(P)$ để chống hội tụ sớm:**
  >
  > Phân phối xác suất Softmax toàn cục được định nghĩa $P_{t,i} = \frac{\exp(s_{t,i}/\tau)}{\sum_{t',j} \exp(s_{t',j}/\tau)}$. Để ngăn mạng dồn toàn bộ xác suất vào một vài frame cố định, ta tính **Temporal Marginal Distribution** bằng cách cộng gộp theo trục không gian: $P_T(t) = \sum_{i=1}^{N} P_{t,i}$. Entropy được tính trực tiếp:
  >
  > $$\mathcal{H}(P) = -\sum_{t=1}^{T} P_T(t) \log\left(P_T(t) + \epsilon\right)$$
  >
  > Nếu xác suất bị co cụm vào một vài khung hình đầu/cuối, $\mathcal{H}(P) \to 0$ và nhận giá trị phạt lớn, buộc mạng phải duy trì độ phủ thời gian.

B. Tối Ưu Hóa Nhóm (Group Relative Policy Optimization)

CRITIC-FREE RL

Vì bước Top-K ngắt gradient ($\nabla = 0$), ta áp dụng GRPO. GRPO loại bỏ hoàn toàn mạng Critic (Value Network), tiết kiệm hơn 60% VRAM so với PPO truyền thống:

1. **Group Rollout:** Với mỗi video, DSTA-Scorer sinh ra G mặt nạ độc lập $\mathbf{m}^{(1)}, \dots, \mathbf{m}^{(G)}$ thông qua lấy mẫu Gumbel-Softmax có nhiệt độ τ.
2. **Đo lường Advantage nội nhóm:**

$$\hat{A}^{(g)} = \frac{R(\mathbf{m}^{(g)}) - \mu_R}{\sigma_R + \epsilon} \quad \text{với} \quad \mu_R = \frac{1}{G}\sum_{g=1}^{G} R(\mathbf{m}^{(g)})$$

3. **Cập nhật Gradient:** Tối đa hóa hàm mục tiêu cắt tỉa tỉ số xác suất (PPO-clip) kết hợp với ràng buộc KL Divergence để giữ ổn định phân phối:

$$\mathcal{L}_{\text{GRPO}}(\theta) = -\frac{1}{G}\sum_{g=1}^{G}\left[\min\left(\rho_g \hat{A}^{(g)}, \text{clip}(\rho_g, 1-\epsilon, 1+\epsilon)\hat{A}^{(g)}\right)\right] + \beta D_{\text{KL}}$$

5. Quản Trị Rủi Ro Kỹ Thuật & Phòng Chống "Reward Hacking"

Hiện Tượng "Bẫy Nội Suy Tuyến Tính"

Cơ chế rủi ro: Trong các phân cảnh video tĩnh (như camera an ninh nhìn góc tường, hoặc người ngồi nói chuyện không đổi nền), nếu Scorer chọn một cách máy móc: *khung hình đầu tiên và khung hình cuối cùng*, bộ Predictor của V-JEPA 2.1 vẫn có thể dễ dàng nội suy các token ở giữa với sai số cực nhỏ.

Hệ quả là chính sách π_θ sẽ bị hội tụ về cực tiểu cục bộ: **luôn chọn các token ở biên thời gian** mà hoàn toàn bỏ qua các chuyển động vi mô chớp nhoáng ở giữa video.

Giải Pháp Phòng Ngự Của Chuyên Gia

- **Phân đoạn Interval-Aware (KiToke):** Không nạp video với độ dài cứng cố định. Dùng thuật toán KiToke chia cắt theo ranh giới ngữ nghĩa động lực học (Dynamic Boundaries), phá vỡ quy luật biên thời gian.
- **Phần thưởng phạt tính đa dạng (Determinantal Point Processes - DPP):** Bổ sung hạng tử Diversity Loss dựa trên thể tích hình học ma trận Gram giữa các token được chọn:

$$\mathcal{L}_{\text{div}}(S) = -\log\det\left(\mathbf{K}_S\right)$$

Nếu các token được chọn quá gần nhau hoặc có biểu diễn tương đương, định thức sẽ tiến về 0 và nhận hình phạt lớn.

> **Chi tiết xây dựng ma trận Gram & tính toán DPP:**
> Với $K = 1024$ tokens được chọn, trích xuất vector biểu diễn chuẩn hóa $\mathbf{z}_k$ ($\|\mathbf{z}_k\|_2 = 1$). Ma trận Gram $\mathbf{K}_S \in \mathbb{R}^{K\times K}$ được tạo bởi tích vô hướng: $\mathbf{K}_S[a,b] = \mathbf{z}_a^\top \mathbf{z}_b$. Định thức $\det(\mathbf{K}_S)$ biểu thị bình phương thể tích hình hộp căng bởi các vector:
>
> - Nếu các token đa dạng (trực giao): $\det(\mathbf{K}_S)$ đạt cực đại, $-\log\det(\mathbf{K}_S)$ nhỏ (không bị phạt).
> - Nếu các token trùng lặp (song song): ma trận phụ thuộc tuyến tính, $\det(\mathbf{K}_S) \to 0$, dẫn tới $-\log\det(\mathbf{K}_S) \to +\infty$ (bị phạt cực nặng).
>
> *Triển khai:* Sử dụng phân rã Cholesky $\mathbf{K}_S + \delta\mathbf{I} = \mathbf{L}\mathbf{L}^\top$ với jitter $\delta = 10^{-4}$ để tính ổn định: $\log\det(\mathbf{K}_S + \delta\mathbf{I}) = 2\sum_{k=1}^{K}\log L_{kk}$.

6. Ma Trận So Sánh Các Phương Pháp Cắt Tỉa Token Video Dài

PHƯƠNG PHÁP	KIẾN TRÚC BỘ CHỌN (POLICY/SCORER)	NGUỒN TÍN HIỆU HƯỚNG DẪN	CHI PHÍ TRÍCH XUẤT FEATURE (INFERENCE)	KHẢ NĂNG CHỐNG REDUNDANCY
Uniform Sampling (Cơ bản)	Không có (Quy tắc cứng)	Không có	0 ms	Rất kém (Dồn cục khung hình tĩnh)
Ý Tưởng Thô Ban Đầu	Mạng MLP đơn lẻ cho từng token	V-JEPA (Hiểu nhầm Pixel Reconstruction)	Chậm nếu map về pixel thô	Kém (Bị bẫy token nền lặp lại)
SCORE	MLP Gating Policy	Output Cross-Entropy Loss của LLM	Phải chạy qua LLM lúc train RL	Khá (Nhưng overfit vào downstream task)
FastVID / InfoMerge	Heuristic Density Peak + Attention	Similarity nội bộ giữa các khung hình	Nhẹ, Training-Free	Tốt (Nhờ DTM và suppression mask)
Đề Xuất Mới (DSTA + V-JEPA)	**Decoupled Spatio-Temporal Attention ($\sim 2.5\text{M}$)**	**V-JEPA 2.1 Latent Loss qua thuật toán GRPO**	**Tối ưu tuyệt đối (Chỉ chạy 1 lần qua VLM Encoder)**	**Xuất sắc (Nhờ Temporal Attention Block triệt tiêu token lặp)**

7. Lộ Trình Triển Khai Thực Nghiệm (Engineering Implementation)

1. **Giai đoạn 1: Chuẩn bị Môi trường & Trích xuất Feature Offline**
   - Lấy trọng số Vision Encoder của **Qwen3-VL** (SigLIP-2) hoặc **InternVL3.5** (InternViT-6B) và đóng băng hoàn toàn.

- Tải mô hình nền tảng **V-JEPA 2.1 (ViT-H/16)** làm môi trường đánh giá thế giới tiềm ẩn.
- Sử dụng tập dữ liệu video đa dạng: Video-CC3M kết hợp Kinetics-700 và ActivityNet để bao phủ đa dạng các chuyển động vật lý.

2. **Giai đoạn 2: Huấn luyện Mạng DSTA-Scorer với GRPO**
   - Huấn luyện DSTA-Scorer bằng thuật toán GRPO với kích thước nhóm $G = 8$.
   - Mỗi vòng lặp, DSTA-Scorer sinh G mask; V-JEPA tính sai số phục hồi latent và trả về reward. Quá trình chỉ mất khoảng 16-24 giờ trên 4 GPU A100 do chỉ tối ưu mạng $\sim 2.5\text{M}$ tham số.
3. **Giai đoạn 3: Tích hợp Triển Khai Suy Luận & Đánh Giá Benchmark**
   - Gỡ bỏ hoàn toàn V-JEPA 2.1 khỏi pipeline suy luận. Pipeline chỉ gồm: $\text{Video} \rightarrow \text{VLM Vision Encoder} \rightarrow \text{DSTA-Scorer} \rightarrow \text{Top-1024 Tokens} \rightarrow \text{LLM}$.
   - Đánh giá đối đầu trên các bộ benchmark video dài hàng đầu: **Video-MME**, **MLVU**, và **LongVideoBench**. Đo lường đồng thời độ chính xác (Accuracy), độ trễ suy luận (TTFT), và tỷ lệ cắt giảm bộ nhớ KV-Cache của LLM.

> **Thông điệp chốt:** *"Bằng cách kết hợp Vision Encoder bản địa của VLM với mạng chú ý phân tách không gian - thời gian (DSTA-Scorer), hệ thống giải quyết triệt để lỗi 'mù thời gian' của MLP. Đồng thời, việc dùng V-JEPA 2.1 làm môi trường chấm điểm trong vòng lặp GRPO biến bài toán thành một cơ chế học tự giám sát vật lý độc lập truy vấn hoàn hảo, giữ vững ngân sách 1024 tokens cho toàn bộ video dài mà không làm rơi rớt sự kiện cốt lõi."*

Tài Liệu Kỹ Thuật Chuyên Sâu — Thiết Kế Module Cắt Tỉa Token Video Dài Cho Multimodal LLMs